

Prozesssynchronisation I

Nebenläufigkeit

Moderne Rechnerarchitekturen erlauben es typischerweise, mehrere Prozesse (oder Threads) **gleichzeitig** auszuführen. Die jeweils laufenden Prozesse werden als **nebenläufige** oder **konkurrente Prozesse** bezeichnet.

Selbst bei Einkernprozessoren können Prozesse bei Vorhandensein von Unterbrechungen*) als nebenläufig betrachtet werden. Nebenläufigkeit bezieht sich also auf **alle** zur Zeit im System **existierenden lauffähigen** Prozesse.

Problemstellung: Dort, wo nebenläufige Prozesse auf dieselben Daten oder Betriebsmittel zugreifen können, entsteht ggf. Notwendigkeit zur **Synchronisation**.

^{*)} Dazu zählt auch das Round-Robin-Scheduling!

Aspekte der Prozesssynchronisation

Deadlock Semaphoren kritische Abschnitte Ressourcenallokation dinierende Philosophen

Betriebsmittel

Als **Betriebsmittel** versteht man all diejenigen **Systemelemente**, die ein Prozess zu seiner **vollständigen** und **korrekten Ausführung** benötigt und die ihm über das Betriebssystem bereitgestellt werden. Dazu gehören unter anderem:

- Geräte (Drucker, Zeigegeräte, Tastatur)
- Speicher (Hauptspeicher, Sekundärspeicher)
- Kommunikationskanäle (Netzwerk)
- etc.

Kritische Abschnitte

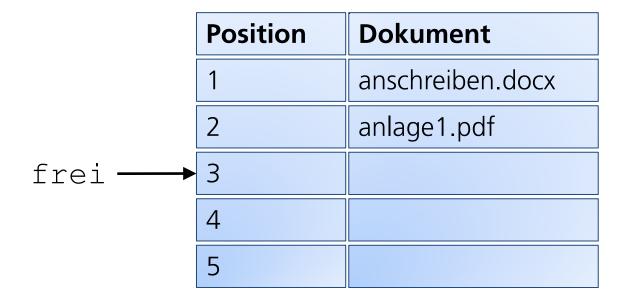
Bei mindestens zwei nebenläufigen Prozessen, die gemeinsame Daten oder Betriebsmittel nutzen können, unterscheidet man:

- 1. unkritische Abschnitte, in denen keine gemeinsamen Daten oder Betriebsmittel genutzt werden oder auf die von allen beteiligten Prozessen *nur lesend* zugegriffen wird,
- 2. kritische Abschnitte, in denen von mindestens einem Prozess schreibend auf gemeinsam genutzte Daten oder Betriebsmittel zugegriffen wird

Ein Abschnitt ist stets **entweder** kritisch **oder** unkritisch, er kann nie beides zugleich sein.

Kritische Abschnitte – Beispiel

Warteschlange eines Druckers:



Variable frei zeigt auf nächsten freien Platz in der Warteschlange.

Kritische Abschnitte – Beispiel

	Position	Dokument
frei →	1	anschreiben.docx
	2	anlage1.pdf
	3	
	4	
	5	

Prozess A:

Kritische Abschnitte – Erwarteter Ausgang

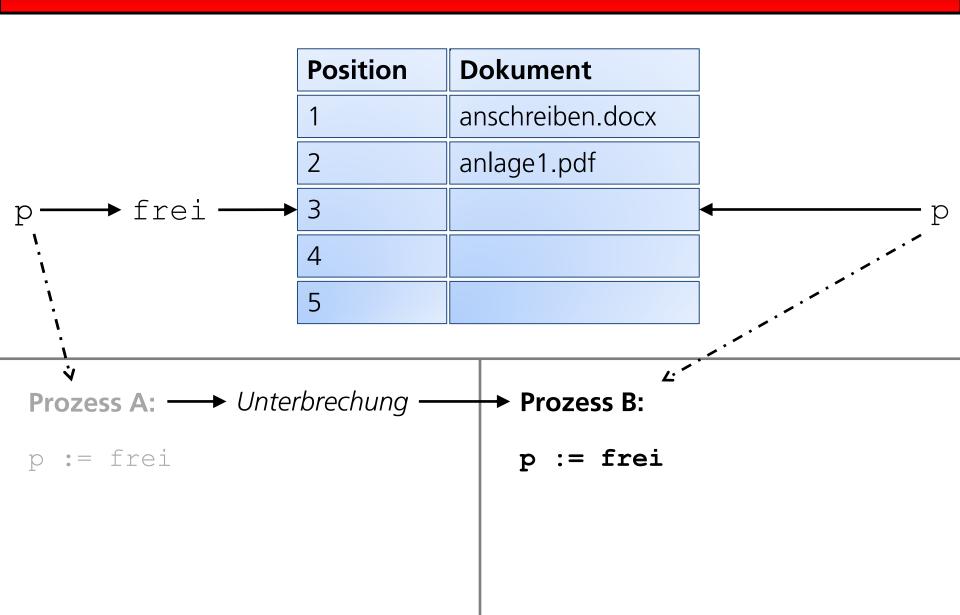
	Position	Dokument
	1	anschreiben.docx
	2	anlage1.pdf
	3	anlage2.pdf
	4	bild1.jpg
frei →	5	

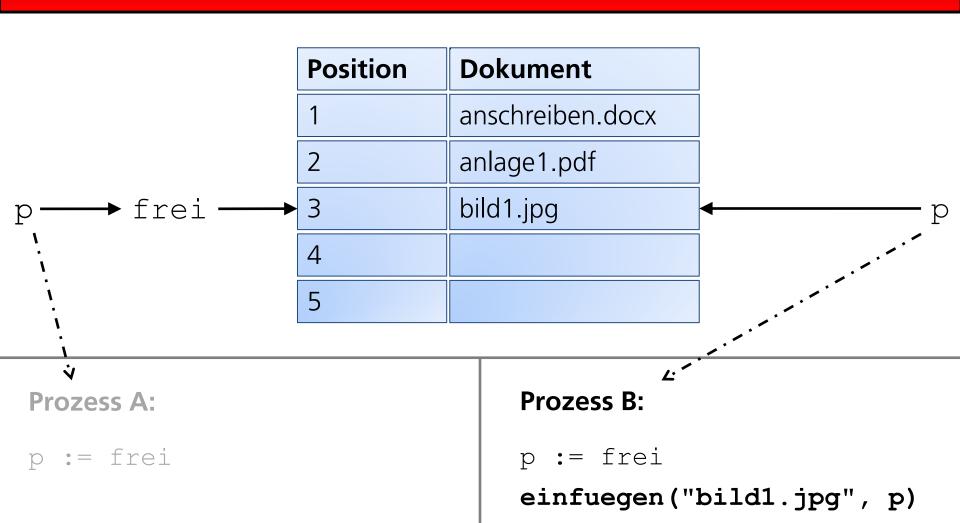
Prozess A:

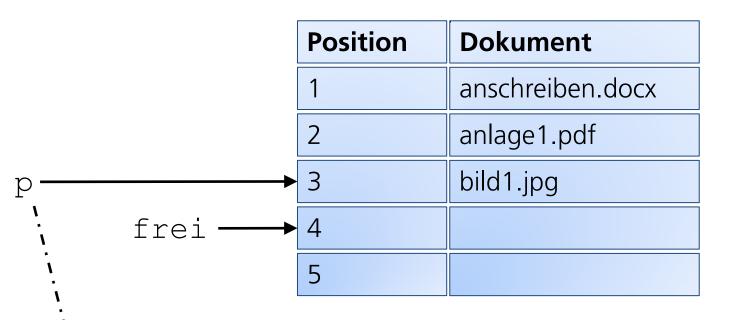
	Position	Dokument
	1	anschreiben.docx
	2	anlage1.pdf
p → frei →	3	
	4	
	5	

Prozess A:

p := frei

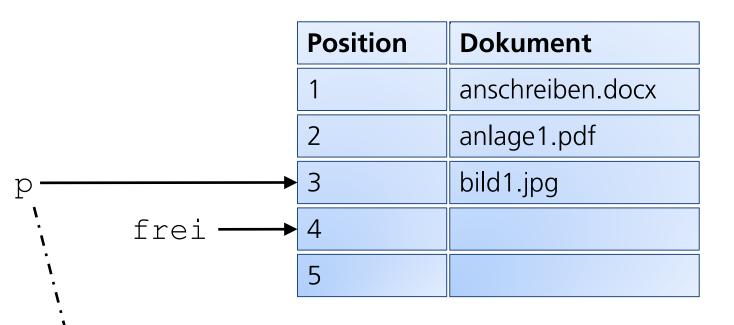






Prozess A:

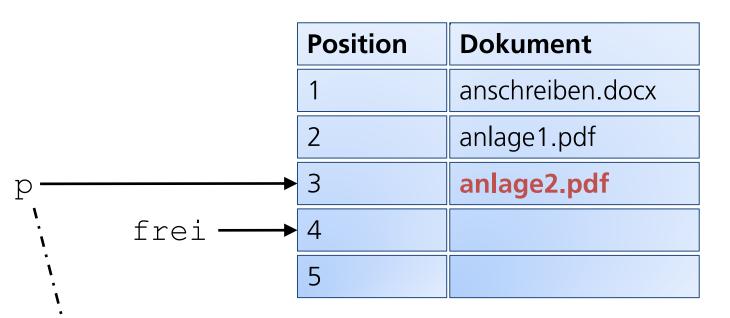
p := frei



Prozess A: ← zurück zu A ← Prozess B:

```
p := frei
```

p := frei
einfuegen("bild1.jpg", p)
frei := p + 1



Prozess A:

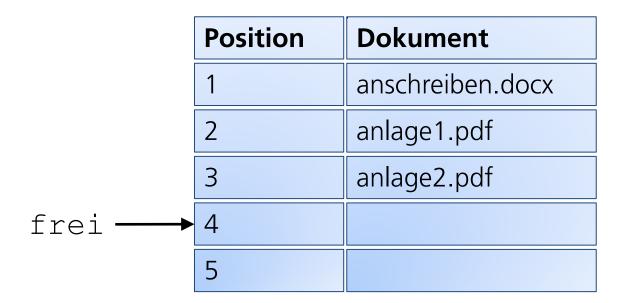
```
p := frei
einfuegen("anlage2.pdf", p)
```

```
p := frei
einfuegen("bild1.jpg", p)
frei := p + 1
```

	Position	Dokument
	1	anschreiben.docx
	2	anlage1.pdf
	3	anlage2.pdf
frei →	4	
	5	

Prozess A:

```
p := frei
einfuegen("bild1.jpg", p)
frei := p + 1
```



Resultat: Die Warteschlange ist wieder konsistent, aber ein Auftrag ist verlorengegangen!

→ **Synchronisation** ist notwendig

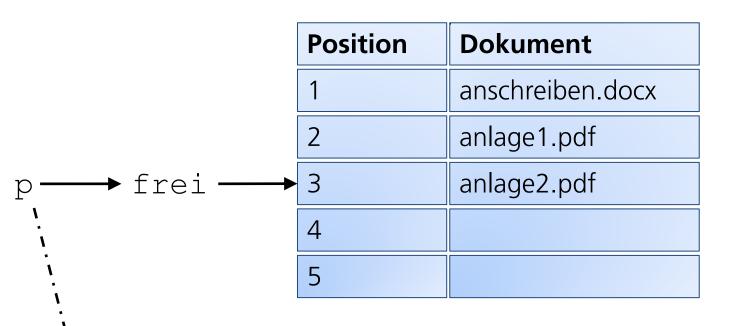
Race Conditions

Da der Zeitpunkt von Unterbrechungen **nicht vorhersagbar** ist, können unterschiedliche, schwer zu kontrollierende Effekte eintreten, die davon abhängen, welcher Prozess zuerst bestimmte Aktionen ausführen kann. Diese Abhängigkeiten nennt man **Race-Conditions** ("Wettrennen").

Im vorangegangenen Beispiel:

- Unterbrechung vor oder nach Einfügen/Zähler verändern?
 - → Geht ein Dokument verloren?
 - → Verliert A oder B sein Dokument?
- Welcher Prozess startet zuerst?
 - → Verliert A oder B sein Dokument?

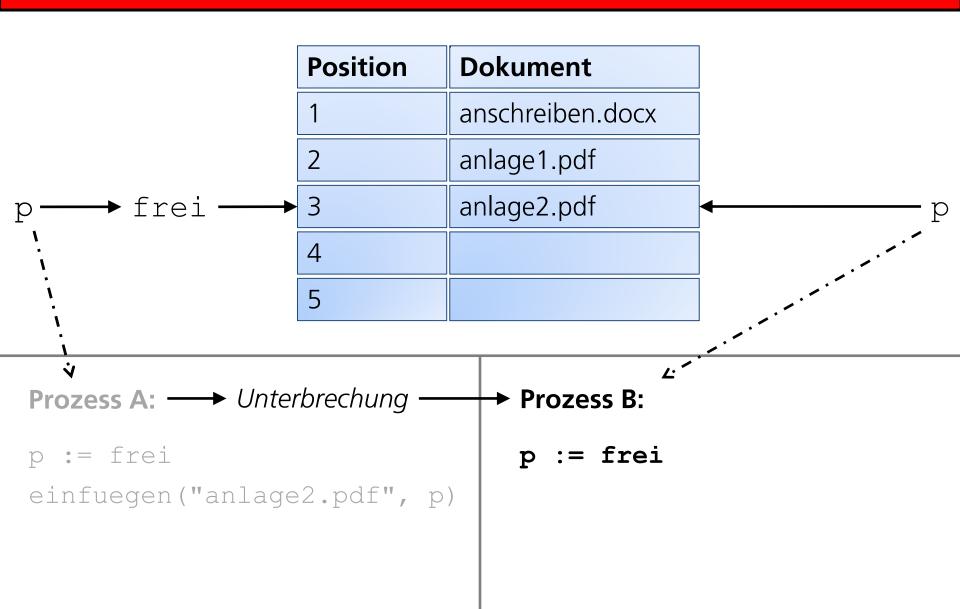
Kritische Abschnitte – Alternativer Ablauf



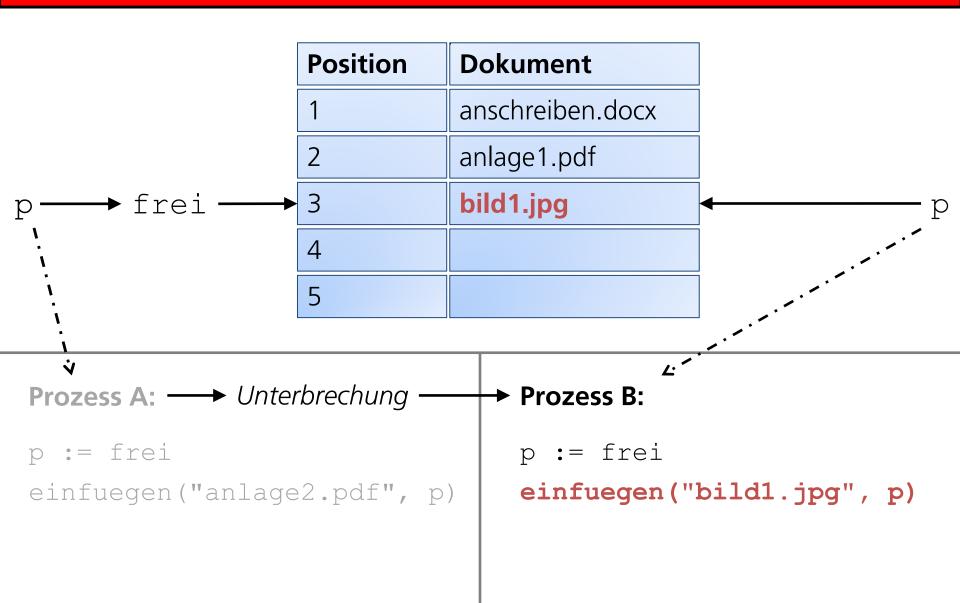
Prozess A:

```
p := frei
einfuegen("anlage2.pdf", p)
```

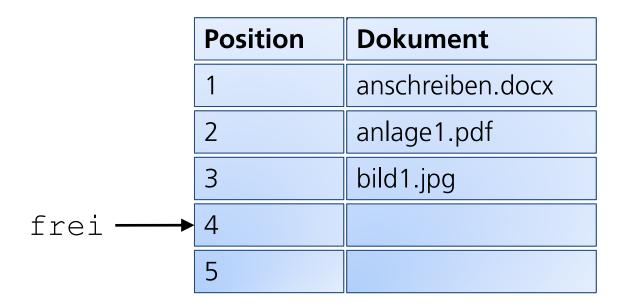
Kritische Abschnitte – Alternativer Ablauf



Kritische Abschnitte – Alternativer Ablauf



Kritische Abschnitte – Alternativer Ablauf – Resultat

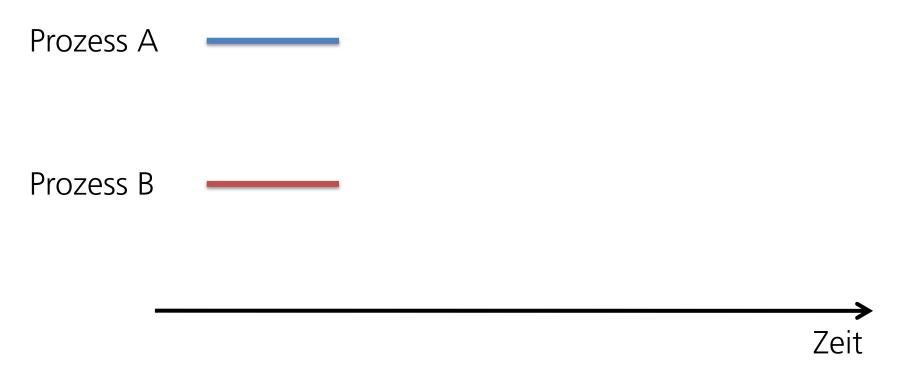


Resultat: Wieder ist die Warteschlange am Ende konsistent, trotzdem ist ebenfalls ein Auftrag verlorengegangen – aber diesmal der andere!

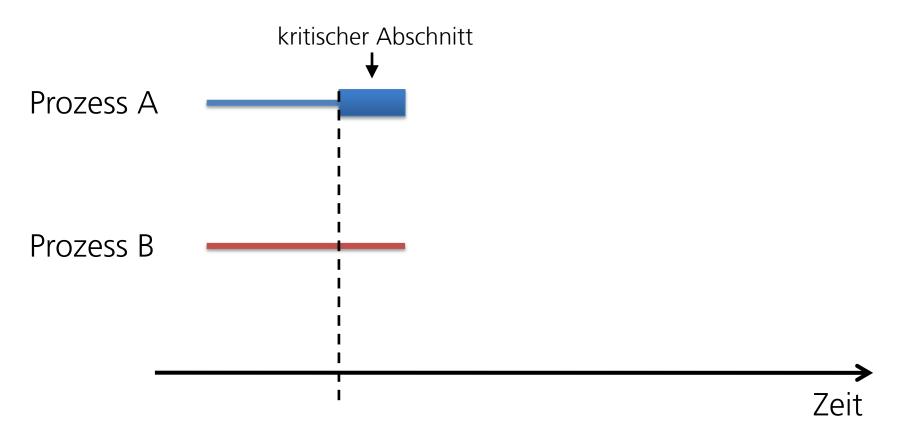
→ Race-Condition, Synchronisation ist notwendig.

(An-)forderungen an kritische Abschnitte (Dijkstra 1965)

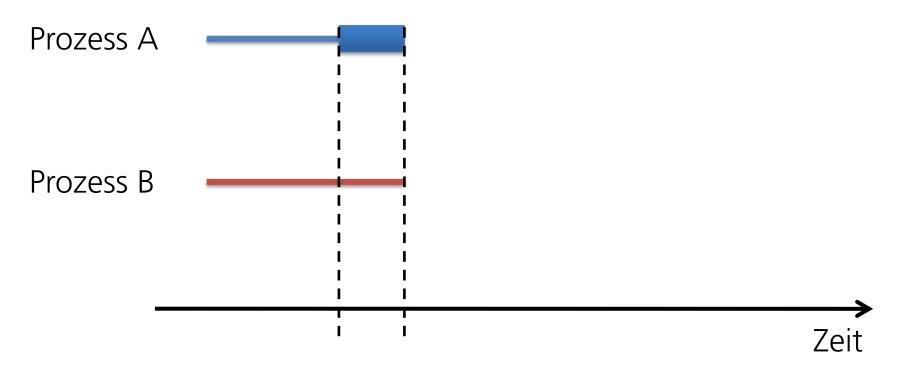
- 1. Zwei Prozesse dürfen **nicht gleichzeitig** in demselben kritischen Abschnitt sein (*mutual exclusion*, kurz: *mutex*).
- 2. Jeder Prozess, der am Eingang eines kritischen Abschnitts wartet, muß irgendwann diesen Abschnitt auch betreten dürfen. **Kein ewiges Warten** darf möglich sein (*fairness condition*).
- 3. Ein Prozess darf außerhalb eines kritischen Abschnitts einen anderen Prozess **nicht blockieren**.
- 4. Es dürfen **keine Annahmen** über die Abarbeitungsgeschwindigkeit oder die Anzahl von Prozessen bzw. Prozessoren gemacht werden.



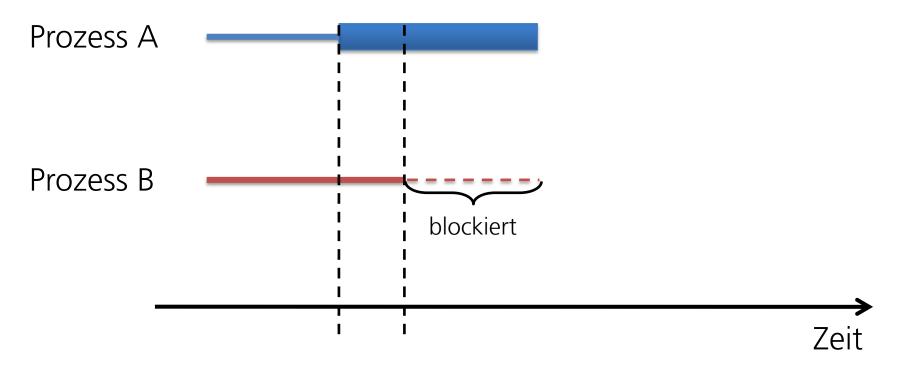
1. Beide Prozesse sind in unkritischen Abschnitten



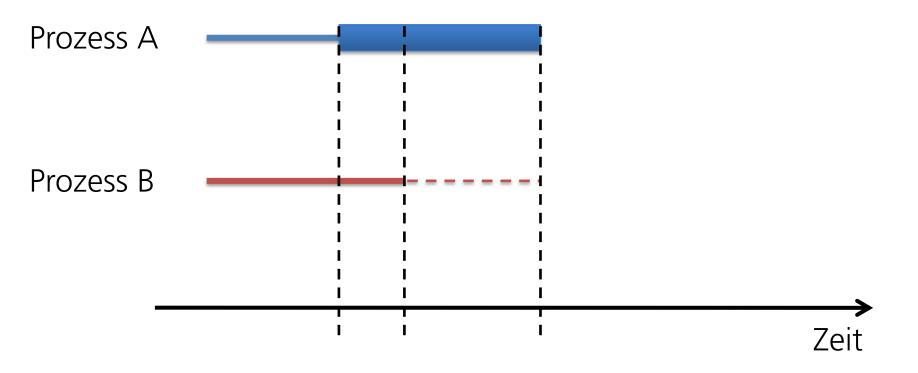
2. Prozess A betritt kritischen Abschnitt Prozess B verbleibt in unkritischem Abschnitt



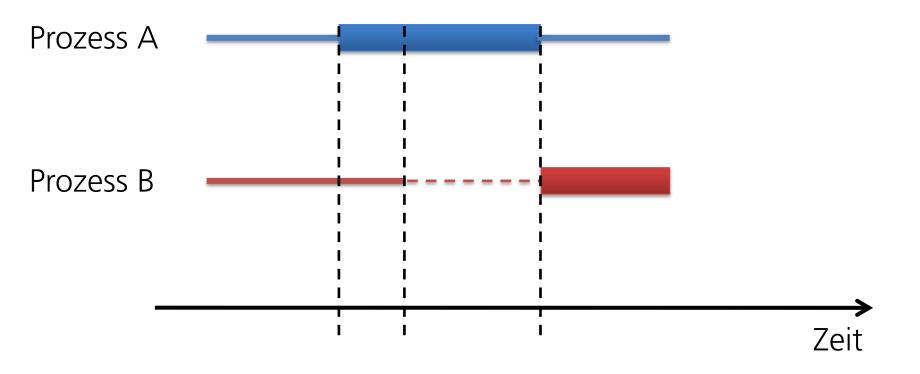
3. Prozess B versucht ebenfalls, kritischen Abschnitt zu betreten, den A noch nicht verlassen hat.



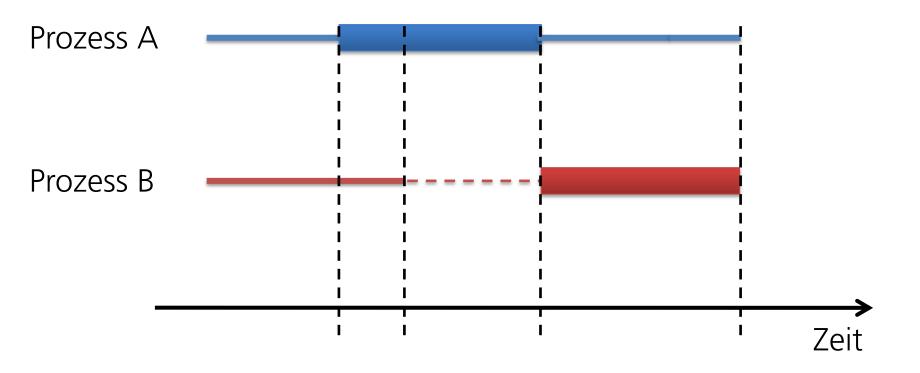
4. Prozess B wechselt in den Zustand "blockiert"



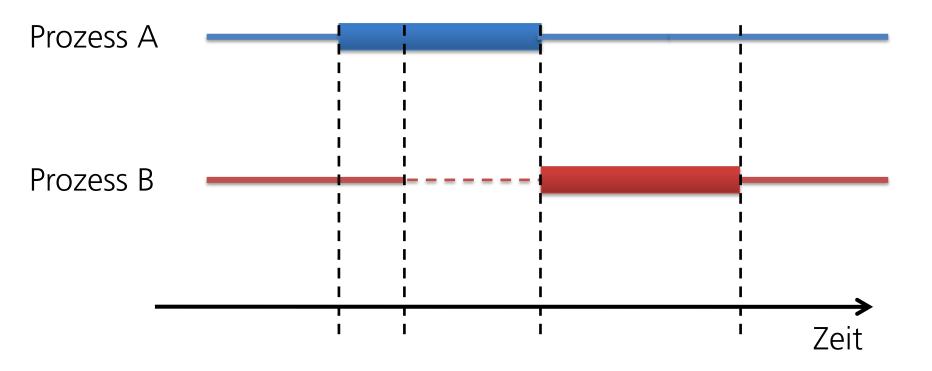
5. Prozess A beendet kritischen Abschnitt Prozess B wird in den Zustand "bereit" versetzt



6. Prozess B kann kritischen Abschnitt betreten, Prozess A ist in unkritischem Abschnitt und kann daher weiterrechnen



7. Prozess B beendet kritischen Abschnitt



8. Beide Prozesse rechnen in unkritischen Abschnitten weiter

Verfahren zum gegenseitigen Ausschluss

Vorbemerkung: Wir betrachten zur Erläuterung der Verfahren hier **zyklische Prozesse** mit jeweils einem kritischen Abschnitt, die nach folgendem Schema abgearbeitet werden:

wiederhole

unkritischer Abschnitt

Eintritt in kritischen Abschnitt

kritischer Abschnitt

Austritt aus kritischem Abschnitt

unkritischer Abschnitt

bis Abbruch

Die im folgenden beschriebenen Szenarien gelten auch für azyklische Prozesse oder mehrere kritische Abschnitte.

Verfahren zum gegenseitigen Ausschluss

Grundsätzlich kommt eine Vielzahl Verfahren zur Sicherstellung gegenseitigen Ausschlusses infrage:

- falloptimierte Softwarelösungen für zwei oder mehr Prozesse
- vom Betriebssystem bereitgestellte generische Lösungen

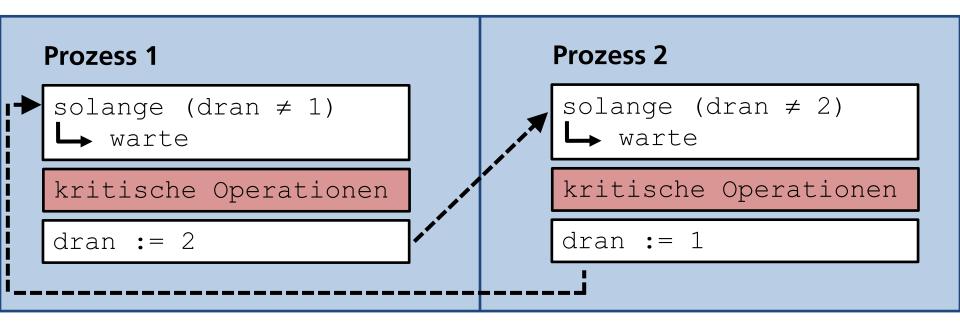
Für diese beiden Varianten ist **Hardwareunterstützung** durch spezielle CPU-Operationen sehr hilfreich.

Außerdem sind noch interessant:

- nachrichtenbasierte Lösungen
- dateisystemspezifische Lösungen (nicht Teil des Kurstextes)

Softwarelösung – Erster Ansatz

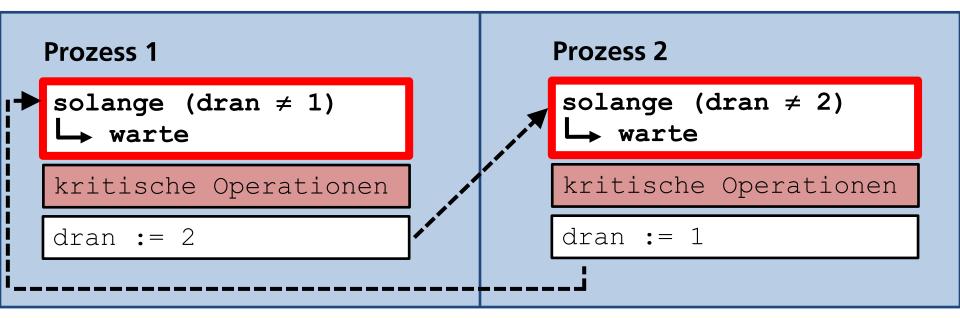
Zutrittsregelung mittels globaler **Zugangsvariablen**, deren Wert festlegt, welcher Prozess als nächstes den kritischen Abschnitt betreten darf:



Hinweis: dran wird mit 1 oder 2 initialisiert

Softwarelösung – Erster Ansatz

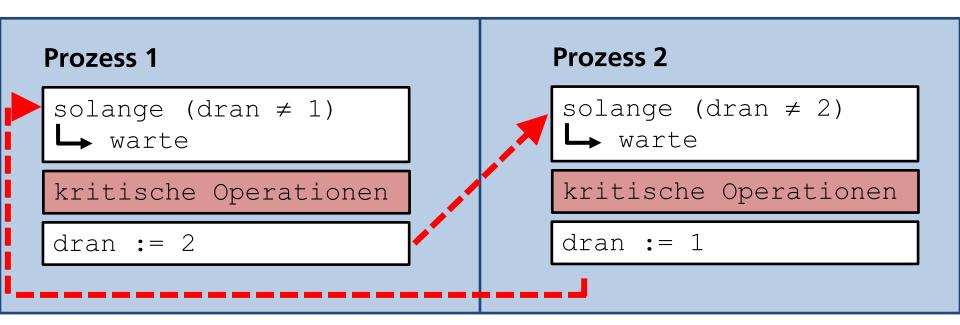
Zutrittsregelung mittels globaler **Zugangsvariablen**, deren Wert festlegt, welcher Prozess als nächstes den kritischen Abschnitt betreten darf:



Probleme: 1. beschäftigtes Warten (*busy wait*)

Softwarelösung – Erster Ansatz

Zutrittsregelung mittels globaler **Zugangsvariablen**, deren Wert festlegt, welcher Prozess als nächstes den kritischen Abschnitt betreten darf:

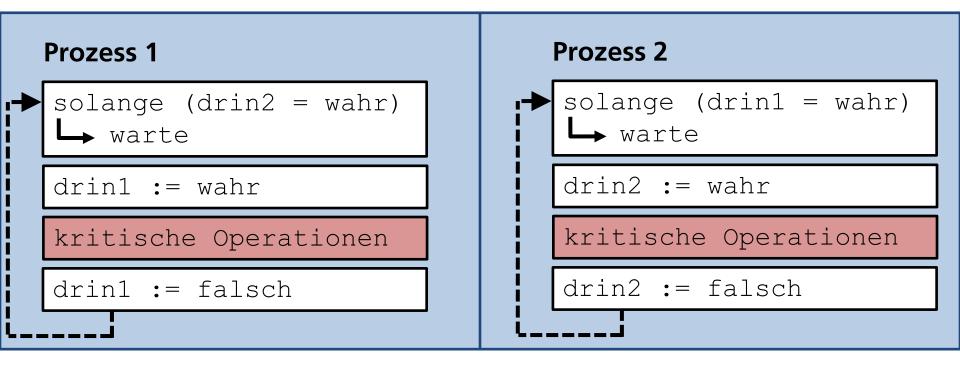


Probleme: 1. beschäftigtes Warten (*busy wait*)

2. erzwungene Abwechslung

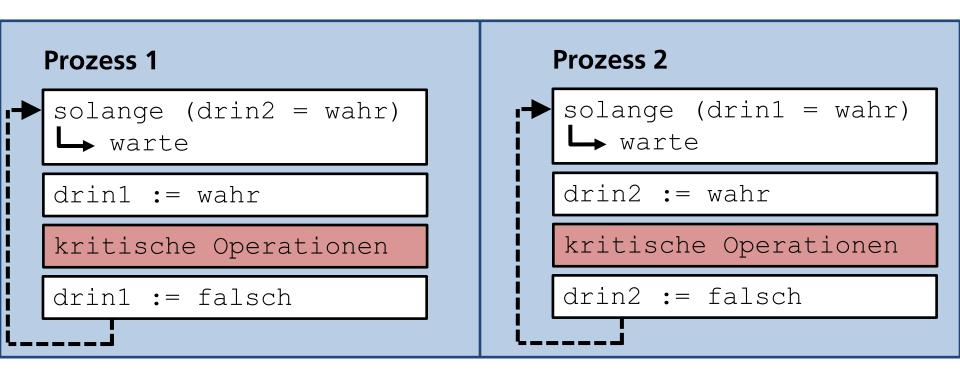
Softwarelösung – Verbesserungsversuch

Invertierung des vorherigen Ansatzes: Statt Zugangsvariable eine **Sperrvariable je Prozess**, die angibt, ob sich der jeweilige Prozess im kritischen Abschnitt befindet:



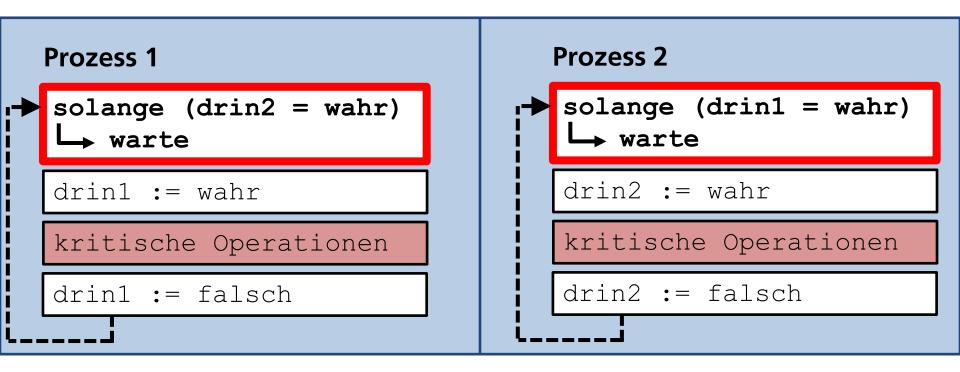
Softwarelösung – Verbesserungsversuch

Hinweis: drin1 und drin2 werden mit falsch initialisiert.



Softwarelösung – Verbesserungsversuch

Probleme: 1. immer noch beschäftigtes Warten (busy wait)



Softwarelösung – Verbesserungsversuch

Probleme: 1. immer noch beschäftigtes Warten (*busy wait*)

2. Unterbrechung kann zu Fehlverhalten führen

Um dies zu verdeutlichen, wird im Folgenden ein mögliches Szenario schrittweise analysiert.

Ausgangssituation: Beide Prozesse gerade gestartet

Prozess 1 hat die CPU

Prozess 1

Prozess 2

- Prozess 1 prüft, ob drin2 den Wert wahr hat.
- Da drin1 und drin2 mit falsch initialisiert wurden, muss Prozess 1 nicht warten und verlässt die Schleife.
- Zufällig ist jetzt die Zeitscheibe des Prozesses abgelaufen.

Prozess 1

solange (drin2 = wahr)

warte

Prozess 2

- Folge: Es findet ein Prozesswechsel auf Prozess 2 statt.
- Dieser prüft, ob drin1 den Wert wahr hat.
- Da Prozess1 diesen Wert noch nicht anpassen konnte, muss auch Prozess 2 nicht warten und verlässt die Schleife.

Prozess 1

Prozess 2

```
solange (drin1 = wahr)
    warte
```

- Prozess 2 setzt den Wert von drin2 auf wahr und betritt den kritischen Abschnitt.
- Zufällig läuft die Zeitscheibe von Prozess 2 ab, bevor er den kritischen Abschnitt verlassen hat.

Prozess 1

Prozess 2

drin2 := wahr

kritische Operationen

- Prozess 1 wurde hinter der Warteschleife unterbrochen und hat von der veränderten Situation nichts bemerkt.
- Er setzt drin1 auf wahr und betritt ebenfalls den kritischen Abschnitt.

Prozess 1

solange (drin2 = wahr)
 warte

drin1 := wahr

kritische Operationen

Prozess 2

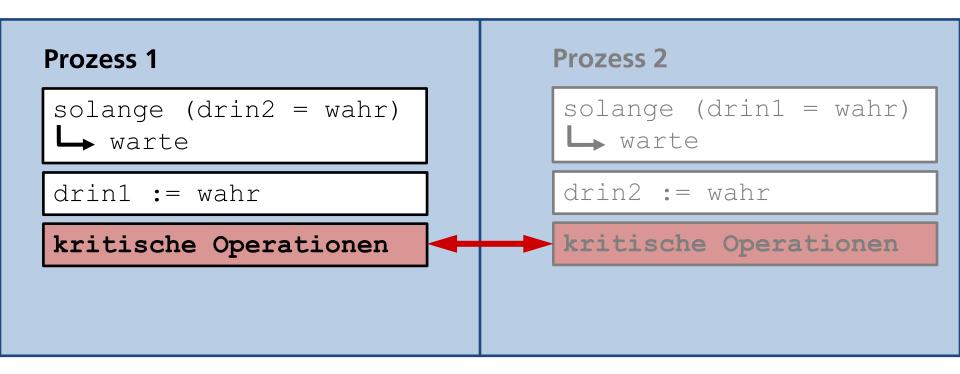
solange (drin1 = wahr)

L→ warte

drin2 := wahr

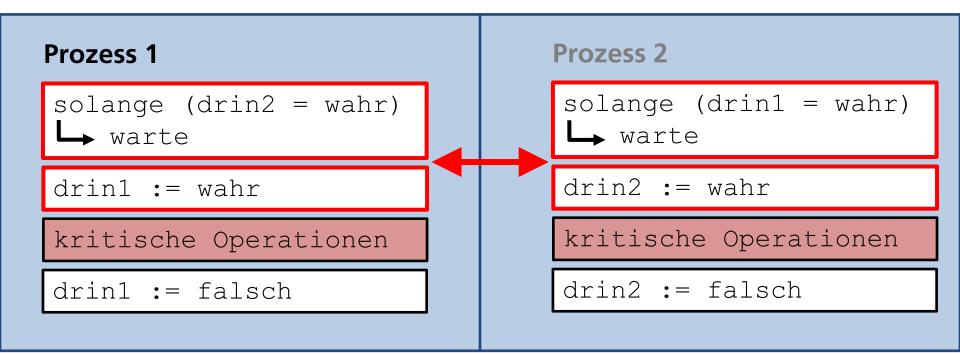
kritische Operationen

Resultat: Beide Prozesse sind im kritischen Abschnitt!



Resultat: Beide Prozesse sind im kritischen Abschnitt!

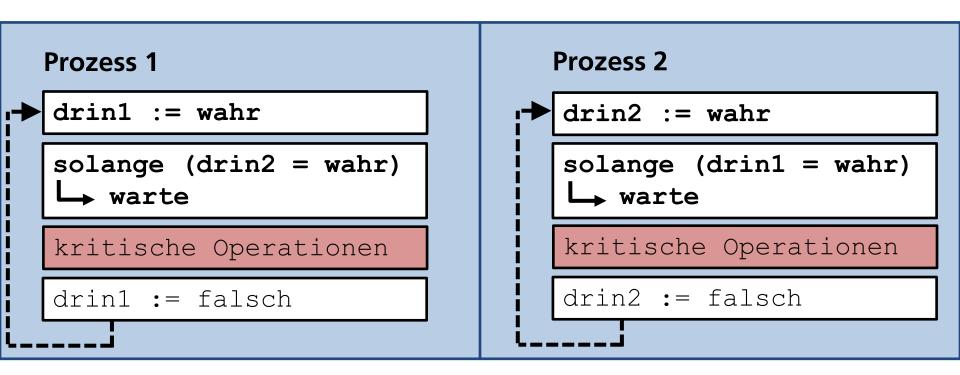
Ursache: Prüfen und Setzen von drin1 und drin2 sind zwei Einzeloperationen, zwischen denen eine Unterbrechung stattfinden kann!



Zweiter Verbesserungsversuch

Lösungsansatz: Vertauschen des Setzens und Prüfens.

Ist das die Lösung? Überlegen Sie selbst für einen Moment!



Annahme: Nach dem Start hat Prozess 1 gerade Gelegenheit bekommen, seine Eintrittsvariable zu setzen. Danach wurde er unterbrochen und Prozess 2 ist dran.

Prozess 2 setzt ebenfalls seine Eintrittsvariable.

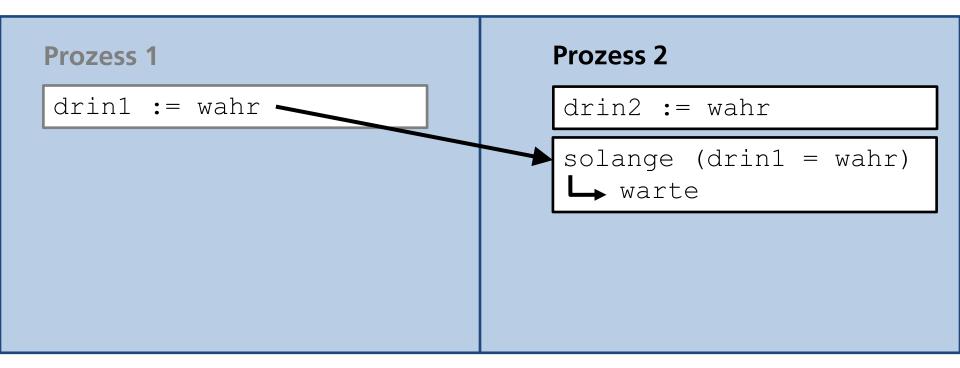
Prozess 1

drin1 := wahr

Prozess 2

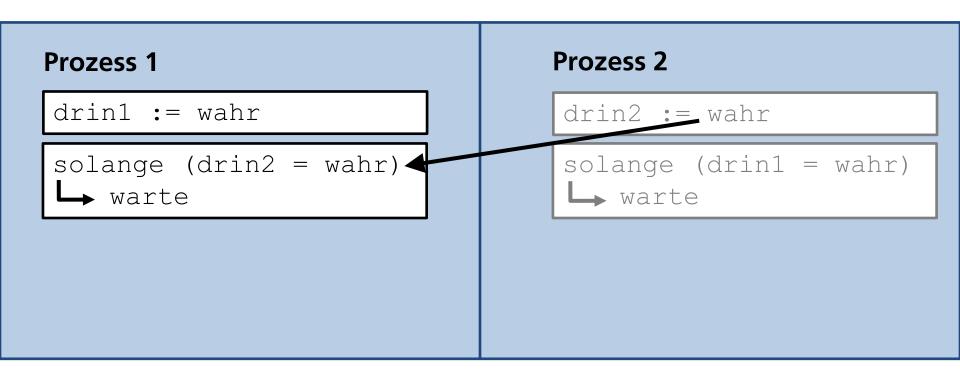
drin2 := wahr

Da die Eintrittsvariable von Prozess 1 jedoch gesetzt ist, kann Prozess 2 die Warteschleife nicht überwinden.



Da die Eintrittsvariable von Prozess 1 jedoch gesetzt ist, kann Prozess 2 die Warteschleife nicht überwinden.

Dasselbe gilt nach Prozesswechsel auch für Prozess 1!



Resultat: Beide Prozesse warten darauf, dass der jeweils andere seine Eintrittsvariable wieder auf false setzt. Die Prozesse **blockieren** sich gegenseitig!

Prozess 1

drin1 := wahr

Prozess 2

drin2 := wahr

solange (drin1 = wahr)
 warte

Gibt es überhaupt eine rein softwarebasierte Lösung für das Problem des gegenseitigen Ausschlusses?

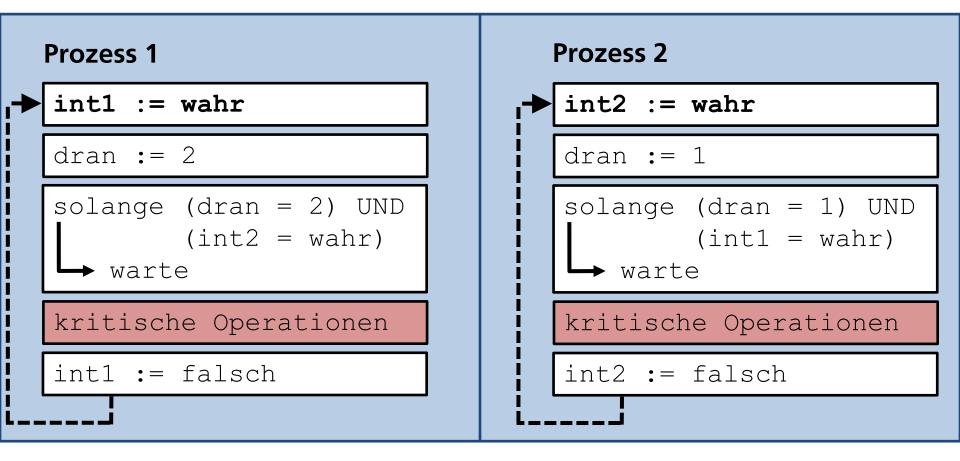


Bild: Tony Hegewald / pixelio.de

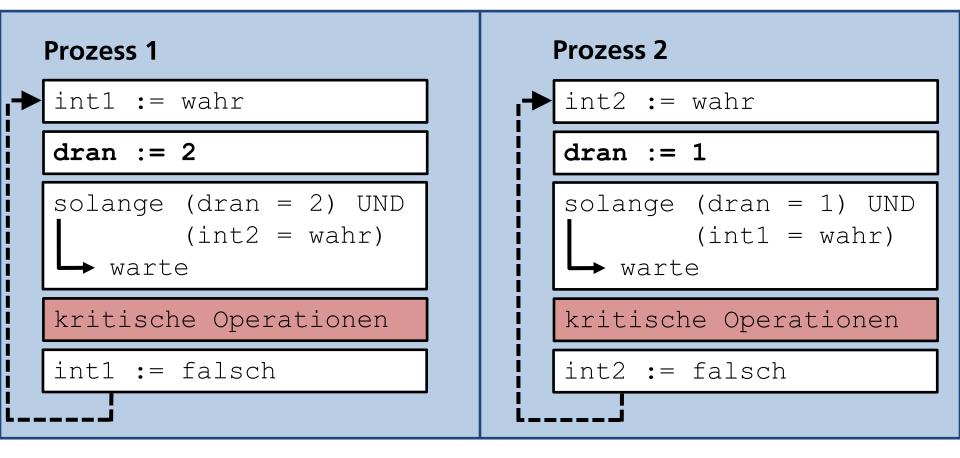
Grundidee: Zunächst bekundet ein Prozess **Interesse**, den kritischen Abschnitt zu betreten. Danach gibt er dem **anderen** Prozess die Möglichkeit, auf dieses Interesse zu reagieren.

Anders als bei den vorangegangenen Ansätzen versucht ein Prozess also nicht, "gierig" die Zulassung zum kritischen Abschnitt zu erhalten, sondern gibt vorher die Kontrolle noch einmal ab.

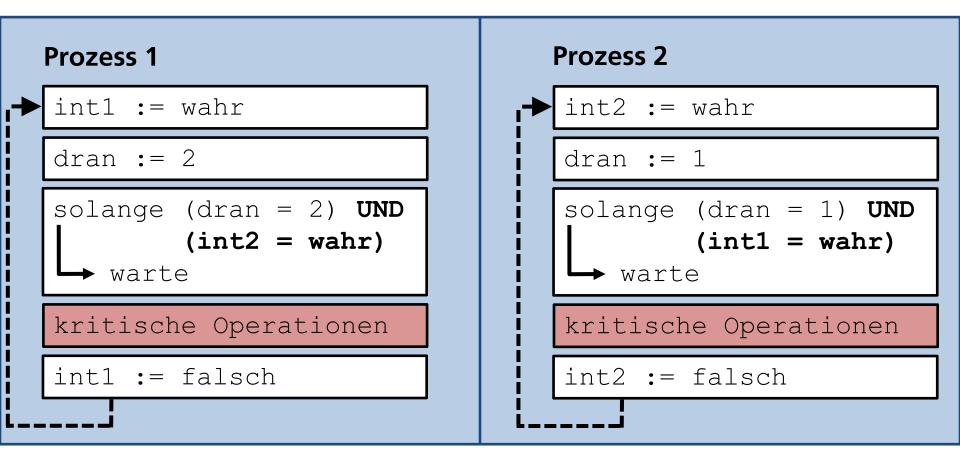
Mit int1/int2 bekunden die Prozesse ihr Interesse, den kritischen Abschnitt zu betreten.



dran gibt an, wer die **Warteschleife überwinden** kann, sofern **beide** Prozesse Interesse haben. Es "gewinnt" hier stets der Prozess, der **zuerst** den Wert für dran gesetzt hat.



Interessiert sich der jeweils andere Prozess **nicht** für den kritischen Abschnitt, wird die Warteschleife sofort überwunden.



- Verallgemeinerung auf N Prozesse ist bei Inkaufnahme höheren Aufwandes möglich,
- beschäftigtes Warten bleibt bestehen

Atomare Operationen

 Softwarelösungen können wesentlich einfacher implementiert werden, wenn die **Unterbrechung** zwischen Lesen und Setzen der Zutrittsvariablen sicher verhindert werden kann.

Zwei Varianten:

- 1. Interrupts **blockieren** → Nur im Kernel-Modus möglich, daher nicht für Nutzerprogramme geeignet,
- 2. Unterstützung durch Hardware mittels geeigneter **atomarer** (ununterbrechbarer) **Operationen**
- Bei Intel-CPUs gibt es dafür u.a. die atomare Operation CMPXCHG (vergleichen und Wert austauschen). Damit sind Softwareimplementierungen wesentlich leichter.
- Busy Wait bleibt!

Zusammenfassung Softwarelösungen

- Gegenseitiger Ausschluss ist notwendig bei Vorhandensein kritischer Abschnitte und konkurrenter Prozesse,
- Softwarelösung für gegenseitigen Ausschluss ist möglich, hat jedoch zwei Probleme:
 - 1. Umständlich, weil nicht unterbrechbares Prüfen und Setzen von Variablen softwarebasiert nicht möglich,
 - 2. Ressourcenintensiv durch beschäftigtes Warten
- Hardware kann mit atomaren Operationen unterstützen, die jedoch nicht das beschäftigte Warten vermeiden.